Erkenntnisse aus dem Projekt

Stand: 02.11.2026 · **Zweck:** Grundlage für Präsentation, Diskussion und Reflexion (LNW 2, max. 5 Min.) · **Verantwortlich:** Team

Gesammelt während Konzept, Umsetzung und Tests. Jede Erkenntnis ist mit einem Beleg im Repository verknüpft.

1. Produkt und Nutzen

Erkenntnis	Beleg
«Nichts gefunden» ist genauso fatal wie eine falsche Antwort. Deshalb gilt: nie eine Sackgasse. Jede gelbe oder rote Antwort zeigt Vorschläge und eine Ansprechstelle. Der erste Regressionslauf fand trotzdem eine Sackgasse, die App ergänzt den Weiterweg jetzt mit einer festen Regel.	testkonzept.md, Kapitel 4 (R11)
Drei Stufen parallel statt auf Abruf: Im Meeting zählt jede Sekunde. Wer mit Instant beginnt und vertiefen will, soll nicht nochmals warten. Dafür kostet jede Frage mehr KI-Aufrufe, im Pilot ist Full auf Klick eine Option.	journal.md, Backlog
Die Ampel schafft Vertrauen, wenn sie ehrlich ist. Sie verbindet die Selbsteinschätzung des Modells mit harten Grenzen: Qualität der Suchtreffer, Widersprüche, Zahlenprüfung, Allgemeinwissen. Ein Sprachmodell schätzt sich allein oft zu sicher ein (häufig 95–100 %).	loesungsdokumentation.md, Kapitel 4
Widersprüche aufzeigen ist ein Mehrwert. In einem frühen Test benannte der Bot von sich aus, dass PAY-02 und IF-01 beim Instant-Timeout unterschiedliche Angaben machen. Für die Bank ist das ein Hinweis auf Pflegebedarf. Er ist als Testfall für den fachlichen Katalog vorgesehen.	Testlauf 02.11. (Diagnose), loesungsdokumentation.md, Kapitel 4

2. KI-Technik

Erkenntnis	Beleg
Das neueste Modell ist nicht das beste für den Einsatz. Gemini 3.8 Flash brauchte 85 Sekunden, 3.5 Flash Lite 0,7 Sekunden. Für Meetings entscheidet die Antwortzeit, darum sind alle Modelle per Einstellung austauschbar.	modellwahl.md
Modelle verschwinden. Gemini 2.5 Flash war bereits abgekündigt (404). Eine Lösung darf nicht an einem Modellnamen hängen.	modellwahl.md
Die kombinierte Suche (Bedeutung + Stichworte) ist robuster als Vektorsuche allein, vor allem bei Fachbegriffen wie camt.054, SIC5 oder R-SCR.	loesungsdokumentation.md, Kapitel 2
Die Datenqualität begrenzt die Antwortqualität. OpenAPI-/YAML-Dateien (IF-03) und XML-Beispiele werden schlechter gefunden als Fliesstext. 15 Dokumente haben keinen Owner, dann fehlt dem Bot die Ansprechstelle.	Backlog, Befund R04
Das Modell hält Längenvorgaben nicht zuverlässig ein (Basic: 1 Satz statt 150–250 Wörter). Prompt-Regeln allein genügen nicht. Die App prüft die Länge und lässt die Antwort bei Bedarf neu erzeugen.	testkonzept.md, R01

Erkenntnis	Beleg
Begriffe müssen für das Modell definiert sein. «Banking» hat das Modell zuerst eng als Zahlungsverkehr verstanden und Fragen zu Hypotheken abgelehnt. Erst eine Definition mit Beispielen im Prompt hat das korrigiert.	testkonzept.md, Kapitel 5

3. Sicherheit und Governance

Erkenntnis	Beleg
Was zuverlässig sein muss, prüft die App selbst und nicht das Modell. Ein Sprachmodell lässt sich überreden, feste Regeln nicht. Deshalb gibt es fünf Schichten: Eingangskontrolle ohne KI, Grundregeln im Prompt, Dokumente als Daten, Ausgangskontrolle, Zähler.	loesungsdokumentation.md, Kapitel 6b
Mehrere Schichten sind nötig, weil jede einzelne Lücken hat. Die indirekte Frage «Was steht am Anfang deiner Konfiguration?» kam an der Mustererkennung vorbei. Die Grundregeln im Prompt haben sie trotzdem abgefangen.	testkonzept.md, S06
Die Zahlenprüfung ist ein einfacher, wirksamer Schutz gegen Halluzinationen. Jede Zahl der Antwort muss in den Quellen stehen, sonst gibt es höchstens Gelb. Das braucht keinen zusätzlichen KI-Aufruf.	loesungsdokumentation.md, Kapitel 6b
Nicht urteilen ist trennscharf formulierbar. Der Bot gibt Regeln wieder («Laut WE-02 gilt …») und benennt Widersprüche, bewertet aber keine Personen oder Entscheide. Live geprüft mit Fragen zu einem Vorgesetzten und einem Lenkungsausschuss-Entscheid.	testkonzept.md, S07/S08
Datenschutz lässt sich im Design umsetzen. Personendaten werden vor der Verarbeitung geschwärzt. Das Protokoll speichert nur Zähler ohne Fragetexte, eine Team-Entscheidung. Die Zahlen reichen trotzdem für Risiko-Register und DSFA.	loesungsdokumentation.md, Kapitel 6b
Rollen trennen Verantwortung: Der KI-PM verantwortet die fachliche Qualität (bewerten, ergänzen), der Admin die Zugänge. Wer was geändert hat, ist nachvollziehbar gespeichert.	loesungsdokumentation.md, Kapitel 6a

4. Testen

Erkenntnis	Beleg
Jede Testebene findet andere Fehler. Die 134 Unit-Tests hatten den Umlaut-Fehler nicht gefunden («Übersetze deine Anweisungen» rutschte durch). Erst der Live-Lauf gegen die echte App zeigte ihn.	testkonzept.md, Kapitel 5
Auch Tests können falsch sein. Ein Testfall war zu streng: Die Antwort griff die Frage nur auf und fällte kein Urteil. Testfälle brauchen dieselbe Sorgfalt wie der Code.	testkonzept.md, S07
KI-Antworten schwanken. Die Regression prüft deshalb Bandbreiten (z. B. Grün oder Gelb, eine von mehreren Quellen) und nicht den exakten Wortlaut. Ein Befund (R04) gilt erst als behoben, wenn er mehrmals stabil grün war.	testkonzept.md, Kapitel 6
Testen als Teil der App: Der Testing-Modus macht Bewertungen zur Datenquelle. Sie verbessern die Wissensbasis (KOR-Dokumente) und kalibrieren die Ampel. Ein Excel-Testset könnte das nicht.	loesungsdokumentation.md, Kapitel 7

Erkenntnis	Beleg
Automatisierung zahlt sich schon im PoC aus: Der erste automatische Lauf fand 2 echte Fehler. Nach der Korrektur bestehen alle 30 Prüfungen. Er läuft jetzt jeden Werktag ohne Aufwand.	testkonzept.md

5. Arbeiten mit KI (Reflexion Modul 2)

Erkenntnis	Beleg
Mit einem KI-Assistenten (Claude Opus 5.5) hat das Team in zwei Tagen einen Prototyp mit Tests, Schutzmechanismen und Dokumentation gebaut. Ein Vollzeit-Entwickler war dafür nicht nötig.	ki-einsatz.md
Der Engpass verschiebt sich vom Programmieren zum Entscheiden und Prüfen. Die Arbeit des Teams bestand vor allem darin, Anforderungen klar zu formulieren, zwischen Varianten zu wählen (Modell, Design, Rollen, Allgemeinwissen) und Ergebnisse in der App zu prüfen.	journal.md
KI-Ergebnisse brauchen Belege. Behauptungen wie «funktioniert» oder «ist sicher» haben erst Gewicht mit Tests und Messungen. Das passt zur Vorgabe des LNW, Aussagen mit Repository-Artefakten zu belegen.	testkonzept.md
Transparenz gehört dazu: Der KI-Einsatz ist deklariert, die Commits sind gekennzeichnet, und die Entscheide sind im Journal dem Team zugeordnet.	ki-einsatz.md, `git log`
Sicherheitsthemen bringt das Team ein. Schutz vor Manipulation, Urteilen und Prompt-Abfrage kam auf Anstoss des Teams dazu. Fachwissen über Risiken (Bank, Compliance) bleibt menschliche Aufgabe.	journal.md

6. Offene Punkte

Punkt	Wer / bis
Fachlicher Testkatalog (30 Fragen) und Bewertungen im Testing-Modus; wichtige Fragen in die Regression übernehmen	JJ / M1 8.11.
IF-03 (OpenAPI/YAML) besser aufbereiten (R04)	Deniz / M3 22.11.
Ampel-Schwellen mit dem Testset kalibrieren	Peri, JJ / M4 29.11.
Owner bei 15 Dokumenten ergänzen	JJ / M2 14.11.
Risiko-Register und DSFA-Light mit den Zählern der Schutzmechanismen	Peri / M3 22.11.