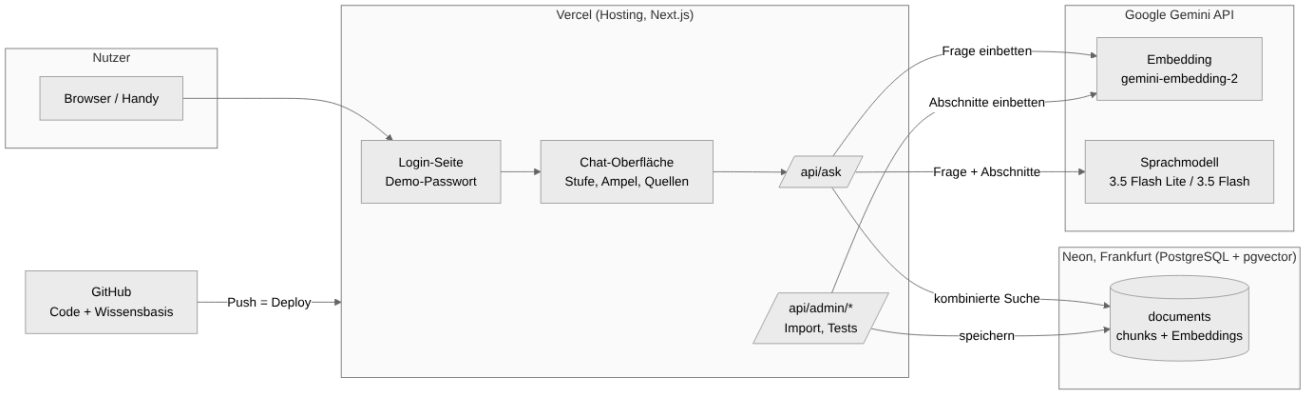
Lösungsdokumentation Briefing-Bot (Beta v0.5)

Stand: 02.11.2026 · **Verantwortlich:** Deniz (Tech Lead) · **Review:** JJ (fachlich), Peri (Governance) **Live:** https://zhaw-lnw-mod2.vercel.app (Demo-Passwort beim Team)

Der Briefing-Bot beantwortet Fragen zu Prozessen, Schnittstellen und Fachthemen der fiktiven Gletscherbank AG in drei Detailstufen (Instant, Basic, Full). Jede Antwort stützt sich ausschliesslich auf die interne Wissensbasis, nennt ihre Quellen und zeigt mit einer Konfidenz-Ampel, wie verlässlich sie ist.

1. Architektur



Komponente	Technologie	Aufgabe	Kosten PoC
Code und Unterlagen	GitHub, Repository `dmaden87/zhaw-lnw-mod2` (öffentlich lesbar)	Versionierung, Nachweis für Dozierende	gratis
Web-App	Next.js 16 auf Vercel (Hobby)	Login, Chat, API	gratis
Vektordatenbank	Neon PostgreSQL mit pgvector, Region Frankfurt	Speichert 498 Abschnitte mit Embeddings	gratis
KI-Modelle	Google Gemini API, bezahlte Stufe	Embeddings und Antworten	Prepaid CHF 16
Nutzungsstatistik	Vercel Web Analytics (`@vercel/analytics`)	Seitenaufrufe und Besuche, ohne Cookies	gratis

Prinzip: **RAG (Retrieval-Augmented Generation).** Das Sprachmodell wird nicht trainiert; es fasst nur zusammen, was die Suche in der Wissensbasis findet. Dadurch sind Antworten belegbar, und eine geänderte Weisung wirkt sofort nach dem nächsten Import.

2. Ablauf einer Frage

1. **Login:** Die App ist durch ein Demo-Passwort geschützt (Cookie, 30 Tage gültig). Zulässig, weil nur fiktive Daten enthalten sind; im Pilot ersetzt durch Single Sign-On.
2. **Frage und Stufe:** Nutzer wählt Instant (5–10 s Lesezeit), Basic (≤ 3 Min.) oder Full (≤ 15 Min.).
3. **Suche (ca. 0,4 s):** Die Frage wird eingebettet. Zwei Suchen laufen kombiniert: nach Bedeutung (Vektorähnlichkeit) und nach Stichworten (deutsche Volltextsuche). Die Ranglisten werden per

Reciprocal Rank Fusion zusammengeführt; je nach Stufe gehen 6, 8 oder 12 Abschnitte weiter. Zusätzlich immer dabei: «Wen frage ich?» aus dem Organigramm (ORG-01).
4. **Antwort (ca. 1–2 s):** Das Sprachmodell erhält Regeln (System-Prompt), Stufe, Frage und Abschnitte und liefert ein festes Format: Antwort, Konfidenz mit Begründung, Quellen, Widersprüche, Vorschläge, Ansprechstelle.
5. **Ampel:** Die Selbsteinschätzung des Modells wird durch die Güte der Suchtreffer begrenzt (siehe Kapitel 4).
6. **Anzeige:** Antwort, Ampel, Quellen mit Owner und Stand, bei Gelb/Rot «Meinst du vielleicht …» und Ansprechstelle, Hinweis «KI-generiert – Quellen prüfen».

Gemessene Antwortzeit gesamt: **1,5–2,5 s** (Ziel Instant < 5 s erfüllt).

3. Wissensbasis

Kennzahl	Wert
Dokumente	60 (Prozesse, Arbeitsanweisungen, Leitfäden, Weisungen, Systemhandbücher, Produktblätter, Organigramm, Glossar, Compliance & Risk, 5 Protokolle, 5 Transkripte, 3 Schnittstellen)
Umfang	ca. 25'000 Wörter
Abschnitte (Chunks)	498, im Schnitt 600 Zeichen, max. ca. 1'500
Embedding	gemini-embedding-2, 768 Dimensionen

Aufbereitung (`db/build_chunks.py`): Word-Dokumente werden in Markdown umgewandelt (`data/text/`), die Metadaten aus dem Dokumentkopf gelesen (Owner, Version/Stand, Klassifikation) und die Texte entlang der Kapitel geteilt. Grosse Tabellen werden zeilenweise geteilt, wobei der Tabellenkopf in jedem Teil erhalten bleibt. Jeder Abschnitt wird mit Dokumenttitel und Kapitel eingebettet, damit er auch allein verständlich ist.

Schnittstellen-Dokumente: Weil die ursprüngliche Wissensbasis kaum technische Schnittstellen enthielt, wurden drei ergänzt: IF-01 PayHub ↔ ScreenGuard (WRICEF, REST/JSON), IF-02 camt.054 (ISO 20022 XML) und IF-03 Payment Initiation API (OpenAPI/YAML).

Import (`/api/admin/ingest`): legt Tabellen und Indizes an und bettet Abschnitte in Paketen von 100 ein. Nur neue oder geänderte Abschnitte werden neu berechnet (Hash-Vergleich). Datenbankschema: `db/schema.sql`.

4. Konfidenz-Ampel

Ampel	Wert	Bedeutung	Verhalten
🟢 Sicher	≥ 85 %	Mehrere übereinstimmende Quellen beantworten die Frage direkt	Antwort mit Quellen
🟡 Ziemlich sicher	60–84 %	Nur eine Quelle, Teilabdeckung oder Widerspruch	zusätzlich Begründung, Vorschläge, Ansprechstelle
🔴 Unsicher	< 60 %	Kontext beantwortet die Frage nicht	sagt das offen, 2–3 Vorschläge, Ansprechstelle – nie eine Sackgasse

Berechnung: Ampelwert = Selbsteinschätzung des Modells, begrenzt durch den besten Suchtreffer (Ähnlichkeit ≥ 0,72 → max. 100; ≥ 0,62 → max. 84; darunter → max. 59). Bei einem Widerspruch zwischen Quellen höchstens Gelb. Die Schwellen sind Startwerte und werden mit dem Testset kalibriert (Schritt 5).

Widerspruchsregel: Meeting-Protokoll vor Transkript, neuere Version vor älterer; jeder Widerspruch wird angezeigt.

5. Modellwahl

Details und Testlauf: `modellwahl.md`.

Aufgabe	Modell	Gemessen
Embedding	gemini-embedding-2	0,3 s
Instant, Basic	gemini-3.5-flash-lite	0,7 s
Full	gemini-3.5-flash (Thinking minimal)	1,2 s
Ausweichmodell bei Überlast	gemini-flash-lite-latest	0,8 s

Erkenntnis: Das neueste Modell (3.8 Flash) brauchte 85 s – für den Einsatz im Meeting untauglich. Modelle werden zudem abgekündigt (2.5 Flash). Deshalb sind alle Modellnamen per Umgebungsvariable austauschbar.

6. Sicherheit und Datenschutz (PoC)

Thema	Umsetzung PoC	Im Pilot
Zugang	Demo-Passwort, Cookie mit SHA-256-Hash	Single Sign-On, Berechtigungen pro Person
Zugangsdaten	Nur als geschützte Umgebungsvariablen in Vercel (`DEMO_PASSWORD`, `DATABASE_URL`, `GEMINI_API_KEY`, `ADMIN_TOKEN`), nie im Repository	Secret-Management der Bank
Admin-Funktionen	`/api/admin/*` nur mit `ADMIN_TOKEN`	entfernt bzw. intern
Daten	ausschliesslich fiktive Daten der Gletscherbank	Freigegebene Dokumente nach Berechtigungs-Audit (MP-05, Gate 1)
KI-Anbieter	Gemini API, bezahlte Stufe: Eingaben werden nicht fürs Training genutzt	Vertrag mit Datenverarbeitung CH/EU, DSFA
Datenhaltung	Datenbank in Frankfurt (EU)	CH/EU gemäss DSFA
Transparenz	«Du sprichst mit einer KI», jede Antwort als KI-generiert gekennzeichnet (vgl. EU AI Act Art. 50)	gleich

7. Betrieb

Aufgabe	Vorgehen
Code ändern	Commit auf `main` → Vercel deployt automatisch (ca. 1–2 Min.)
Wissensbasis ändern	Dokument in `data/` ersetzen → `python3 db/build_chunks.py` → committen → nach Deploy `/api/admin/ingest?step=data` aufrufen, bis `remaining` 0 ist

Aufgabe	Vorgehen
Modell wechseln	Umgebungsvariable `EMBED_MODEL`, `GEN_MODEL_FAST`, `GEN_MODEL_FULL` oder `GEN_MODEL_FALLBACK` in Vercel setzen und neu deployen (Achtung: neues Embedding-Modell erfordert Neu-Import)
Diagnose	`/api/admin/ask?q=…&level=…` zeigt Suchtreffer, Scores und Zeiten; `/api/admin/search?q=…` nur die Suche; Logs im Vercel-Dashboard
Nutzung auswerten	Vercel-Dashboard → Analytics (Seitenaufrufe, Besuche, Geräte) – Beleg für KPI «Nutzungsrate»
Kosten prüfen	Google AI Studio → Nutzung; Vercel und Neon im Dashboard

8. Erste Testergebnisse (02.11.2026)

Frage	Stufe	Ergebnis	Zeit
Was passiert bei einem Timeout im Instant Payment?	Basic	🟢 85 %, korrekt, Quellen PAY-02, IF-01, SH-01	2,4 s
Darf der KI-Assistent im Fraud-Jour-fixe mitlaufen?	Instant	🟡 84 %, inhaltlich richtig («Nein»), Quelle nur WE-03	2,1 s
Wie hoch sind die Hypothekarzinsen? (nicht in der Wissensbasis)	Instant	🔴 0 %, ehrlich «nicht im Kontext», 3 Vorschläge, Ansprechstelle	1,5 s
Wo steht in der camt.054 die QR-Referenz? (nur Suche)	–	Top 3 Treffer alle aus IF-02	0,4 s

9. Bekannte Schwächen und nächste Schritte

Befund	Massnahme	Wer / bis
Entscheid E2 aus MP-05 wird bei der Fraud-Frage nicht gefunden	Testfall aufnehmen; Suche und Abschnittsgrösse für Protokolle prüfen	JJ, Deniz / M3 22.11.
Bei Gelb fehlen teilweise die Vorschläge	Prompt-Regel schärfen	Deniz / M3
Basic-Antwort vermischte zwei Timeout-Arten	Testfall aufnehmen, Prompt-Regel «Begriffe nicht vermischen»	JJ, Deniz / M3
XML-Beispiel in IF-02 wird in der Aufbereitung zerlegt	Code-Blöcke in `build_chunks.py` erhalten	Deniz / M3
Ampel-Schwellen sind Startwerte	Kalibrierung mit Testset (30 Fragen)	Peri, JJ / M4 29.11.
15 Dokumente ohne Owner im Kopf (Leitfäden, Transkripte, 2 Produktblätter)	Owner ergänzen vor Freeze	JJ / M2 14.11.