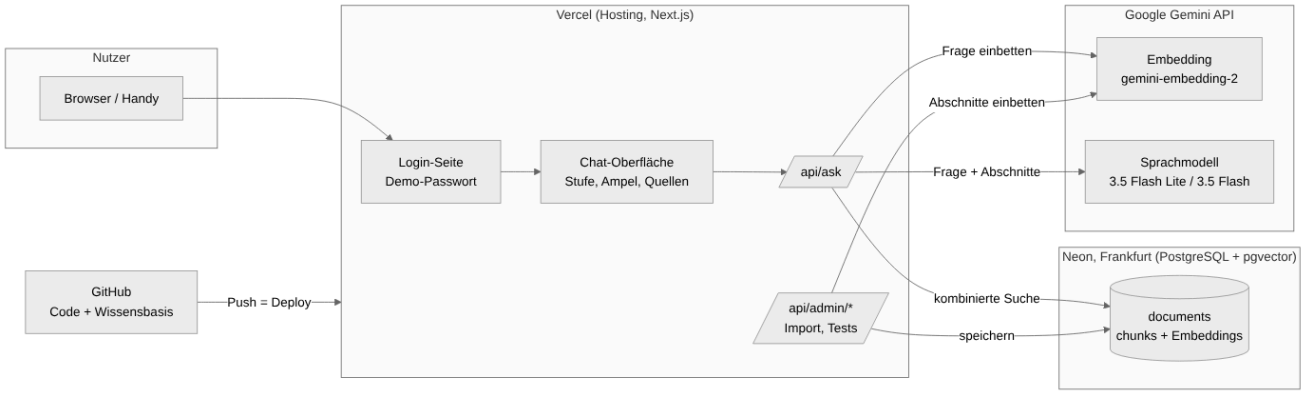
# Lösungsdokumentation Briefing-Bot (Beta v0.5)

**Stand:** 02.11.2026 · **Verantwortlich:** Deniz (Tech Lead) · **Review:** JJ (fachlich), Peri (Governance) **Live:** https://zhaw-lnw-mod2.vercel.app (Demo-Passwort beim Team)

Der Briefing-Bot beantwortet Fragen zu Prozessen, Schnittstellen und Fachthemen der fiktiven Gletscherbank AG in drei Detailstufen (Instant, Basic, Full). Jede Antwort stützt sich ausschliesslich auf die interne Wissensbasis, nennt ihre Quellen und zeigt mit einer Konfidenz-Ampel, wie verlässlich sie ist.

## 1. Architektur




| Komponente | Technologie | Aufgabe | Kosten PoC |
|---|---|---|---|
| Code und Unterlagen | GitHub, Repository `dmaden87/zhaw-lnw-mod2` (öffentlich lesbar) | Versionierung, Nachweis für Dozierende | gratis |
| Web-App | Next.js 16 auf Vercel (Hobby) | Login, Chat, API | gratis |
| Vektordatenbank | Neon PostgreSQL mit pgvector, Region Frankfurt | Speichert 498 Abschnitte mit Embeddings | gratis |
| KI-Modelle | Google Gemini API, bezahlte Stufe | Embeddings und Antworten | Prepaid CHF 16 |
| Nutzungsstatistik | Vercel Web Analytics (`@vercel/analytics`) | Seitenaufrufe und Besuche, ohne Cookies | gratis |

Prinzip: **RAG (Retrieval-Augmented Generation).** Das Sprachmodell wird nicht trainiert; es fasst nur zusammen, was die Suche in der Wissensbasis findet. Dadurch sind Antworten belegbar, und eine geänderte Weisung wirkt sofort nach dem nächsten Import.

## 2. Ablauf einer Frage

1. **Login:** Anmeldung mit Benutzername und Passwort (signierte Sitzung, 12 Std. gültig). Rollen siehe Kapitel 6a. Im Pilot ersetzt durch Single Sign-On.
2. **Frage und Stufe:** Jede Frage erzeugt alle drei Stufen parallel – Instant (5–10 s Lesezeit), Basic (≤ 3 Min.) und Full (≤ 15 Min.). Instant ist meist zuerst bereit; Umschalten zeigt die anderen Stufen ohne neue Wartezeit.

3. **Suche (ca. 0,4 s):** Die Frage wird eingebettet. Zwei Suchen laufen kombiniert: nach Bedeutung (Vektorähnlichkeit) und nach Stichworten (deutsche Volltextsuche). Die Ranglisten werden per Reciprocal Rank Fusion zusammengeführt; je nach Stufe gehen 6, 8 oder 12 Abschnitte weiter. Zusätzlich immer dabei: «Wen frage ich?» aus dem Organigramm (ORG-01).
4. **Antwort (ca. 1–2 s):** Das Sprachmodell erhält Regeln (System-Prompt), Stufe, Frage und Abschnitte und liefert ein festes Format: Antwort, Konfidenz mit Begründung, Quellen, Widersprüche, Vorschläge, Ansprechstelle.
5. **Ampel:** Die Selbsteinschätzung des Modells wird durch die Güte der Suchtreffer begrenzt (siehe Kapitel 4).
6. **Anzeige (Design-Konzept 1, Desktop und Handy):** Quellen sind anklickbar und öffnen das Dokument in einem neuen Tab, direkt beim zitierten Kapitel (hervorgehoben). Dazu Antwort, Ampel, Quellen mit Owner und Stand, bei Gelb/Rot «Meinst du vielleicht …» und Ansprechstelle, Hinweis «KI-generiert – Quellen prüfen».

Gemessene Antwortzeit gesamt: **1,5–2,5 s** (Ziel Instant < 5 s erfüllt).

## 3. Wissensbasis

| Kennzahl | Wert |
|---|---|
| Dokumente | 60 (Prozesse, Arbeitsanweisungen, Leitfäden, Weisungen, Systemhandbücher, Produktblätter, Organigramm, Glossar, Compliance & Risk, 5 Protokolle, 5 Transkripte, 3 Schnittstellen) |
| Umfang | ca. 25'000 Wörter |
| Abschnitte (Chunks) | 498, im Schnitt 600 Zeichen, max. ca. 1'500 |
| Embedding | gemini-embedding-2, 768 Dimensionen |

**Aufbereitung** (`db/build_chunks.py`): Word-Dokumente werden in Markdown umgewandelt (`data/text/`), die Metadaten aus dem Dokumentkopf gelesen (Owner, Version/Stand, Klassifikation) und die Texte entlang der Kapitel geteilt. Grosse Tabellen werden zeilenweise geteilt, wobei der Tabellenkopf in jedem Teil erhalten bleibt. Jeder Abschnitt wird mit Dokumenttitel und Kapitel eingebettet, damit er auch allein verständlich ist.

**Schnittstellen-Dokumente:** Weil die ursprüngliche Wissensbasis kaum technische Schnittstellen enthielt, wurden drei ergänzt: IF-01 PayHub ↔ ScreenGuard (WRICEF, REST/JSON), IF-02 camt.054 (ISO 20022 XML) und IF-03 Payment Initiation API (OpenAPI/YAML).

**Upload in der App** (`/api/documents`): Umwandlung mit mammoth (Word) bzw. unpdf (PDF), Aufteilung mit derselben Logik wie `build_chunks.py`, Abschnitts-IDs ab 100'000, Herkunft `upload`. Hochgeladene Dokumente liegen nur in der Datenbank, nicht im Repository.

**Import** (`/api/admin/ingest`): legt Tabellen und Indizes an und bettet Abschnitte in Paketen von 100 ein. Nur neue oder geänderte Abschnitte werden neu berechnet (Hash-Vergleich). Datenbankschema: `db/schema.sql`.

## 4. Konfidenz-Ampel

| Ampel | Wert | Bedeutung | Verhalten |
|---|---|---|---|
| 🟢 Sicher | ≥ 85 % | Mehrere übereinstimmende Quellen beantworten die Frage direkt | Antwort mit Quellen |

| Ampel | Wert | Bedeutung | Verhalten |
|---|---|---|---|
| 🟡 Ziemlich sicher | 60–84 % | Nur eine Quelle, Teilabdeckung oder Widerspruch | zusätzlich Begründung, Vorschläge, Ansprechstelle |
| 🔴 Unsicher | < 60 % | Kontext beantwortet die Frage nicht | sagt das offen, 2–3 Vorschläge, Ansprechstelle – nie eine Sackgasse |

**Berechnung:** Ampelwert = Selbsteinschätzung des Modells, begrenzt durch den besten Suchtreffer (Ähnlichkeit ≥ 0,72 → max. 100; ≥ 0,62 → max. 84; darunter → max. 59). Bei einem Widerspruch zwischen Quellen höchstens Gelb. Die Schwellen sind Startwerte und werden mit dem Testset kalibriert (Schritt 5).

**Kalibrierung durch Testbewertungen:** Wurde eine sehr ähnliche Frage (Ähnlichkeit ≥ 0,88) im Testing-Modus bewertet, passt das die Ampel an: «falsch» → höchstens 55 % (Rot), «teilweise» → höchstens 75 % (Gelb), «richtig» → +5 Punkte (innerhalb der Suchgrenze). Wurde dazu ergänzendes Wissen erfasst und wird es jetzt gefunden, entfällt die Abwertung. Die Begründung der Ampel nennt die Kalibrierung.

**Widerspruchsregel:** Meeting-Protokoll vor Transkript, neuere Version vor älterer; jeder Widerspruch wird angezeigt.

## 5. Modellwahl

Details und Testlauf: `modellwahl.md`.

| Aufgabe | Modell | Gemessen |
|---|---|---|
| Embedding | gemini-embedding-2 | 0,3 s |
| Instant, Basic | gemini-3.5-flash-lite | 0,7 s |
| Full | gemini-3.5-flash (Thinking minimal) | 1,2 s |
| Ausweichmodell bei Überlast | gemini-flash-lite-latest | 0,8 s |

Erkenntnis: Das neueste Modell (3.8 Flash) brauchte 85 s – für den Einsatz im Meeting untauglich. Modelle werden zudem abgekündigt (2.5 Flash). Deshalb sind alle Modellnamen per Umgebungsvariable austauschbar.

## 6. Sicherheit und Datenschutz (PoC)

| Thema | Umsetzung PoC | Im Pilot |
|---|---|---|
| Zugang | Benutzer mit Rollen (User, Super-User, KI-PM), signierte Sitzung (HMAC, `SESSION_SECRET`) | Single Sign-On, Rollen aus dem Verzeichnis der Bank |
| Zugangsdaten | Nur als geschützte Umgebungsvariablen in Vercel (`DEMO_PASSWORD`, `SESSION_SECRET`, `DATABASE_URL`, `GEMINI_API_KEY`, `ADMIN_TOKEN`), nie im Repository | Secret-Management der Bank |
| Admin-Funktionen | `/api/admin/*` nur mit `ADMIN_TOKEN` | entfernt bzw. intern |
| Daten | ausschliesslich fiktive Daten der Gletscherbank | Freigegebene Dokumente nach Berechtigungs-Audit (MP-05, Gate 1) |

| Thema | Umsetzung PoC | Im Pilot |
|---|---|---|
| KI-Anbieter | Gemini API, bezahlte Stufe: Eingaben werden nicht fürs Training genutzt | Vertrag mit Datenverarbeitung CH/EU, DSFA |
| Datenhaltung | Datenbank in Frankfurt (EU) | CH/EU gemäss DSFA |
| Transparenz | «Du sprichst mit einer KI», jede Antwort als KI-generiert gekennzeichnet (vgl. EU AI Act Art. 50) | gleich |

## 6a. Rollenkonzept

| Rolle | Darf |
|---|---|
| User | Fragen stellen, Antworten und Quellen sehen, Dokumente lesen |
| Super-User | zusätzlich Dokumente hochladen, ersetzen, aktivieren und inaktivieren |
| KI-PM | zusätzlich Testing- und Adjustment-Modus (Antworten bewerten, Wissen ergänzen) und Benutzer verwalten |

- **Benutzerverwaltung:** Seite «Benutzer» (nur KI-PM): anlegen, Rolle ändern, sperren/entsperren, Passwort ändern. Passwörter gespeichert als scrypt-Hash, nie im Klartext.
- **Start-Zugang:** Benutzername `admin` mit dem `DEMO_PASSWORD` ist immer KI-PM – zum Einrichten und als Notfallzugang.
- **Durchsetzung:** Jede API prüft die Rolle serverseitig und bei echten Benutzern zusätzlich, ob sie noch aktiv sind; die Oberfläche blendet nicht erlaubte Funktionen nur aus.
- **Nachvollziehbarkeit:** Hochladen, Ersetzen, Aktivieren und Bewertungen speichern den Benutzernamen (`updated_by`, `rated_by`).
- **Pilot:** Rollen aus dem Single Sign-On der Bank übernehmen statt eigener Benutzerverwaltung.

## 7. Betrieb

| Aufgabe | Vorgehen |
|---|---|
| Code ändern | Commit auf `main` → Vercel deployt automatisch (ca. 1–2 Min.) |
| Wissensbasis ändern | Dokument in `data/` ersetzen → `python3 db/build_chunks.py` → committen → nach Deploy `/api/admin/ingest?step=data` aufrufen, bis `remaining` 0 ist |
| Modell wechseln | Umgebungsvariable `EMBED_MODEL`, `GEN_MODEL_FAST`, `GEN_MODEL_FULL` oder `GEN_MODEL_FALLBACK` in Vercel setzen und neu deployen (Achtung: neues Embedding-Modell erfordert Neu-Import) |
| Wissensbasis verwalten | Seite «Wissensbasis»: alle Dokumente mit Kategorie, Owner, Stand und Anzahl Abschnitte; öffnen (neuer Tab); **aktivieren/inaktivieren** (inaktive Dokumente bleiben gespeichert, werden aber nicht durchsucht); **hochladen** von Word, PDF, Markdown oder Text (max. 4 MB) – das Dokument wird umgewandelt, in Abschnitte geteilt, eingebettet und ist sofort durchsuchbar; **ersetzen** einer bestehenden Fassung (ID, Titel, Kategorie und Status bleiben, Inhalt und Abschnitte werden neu erzeugt). Upload und Ersetzen laufen als Transaktion: Bei einem Fehler bleibt der bisherige Stand unverändert. Nur Rollen Super-User und KI-PM. |

| Aufgabe | Vorgehen |
|---|---|
| Testing- und Adjustment-Modus | Schalter oben im Briefing, nur für die Rolle KI-PM sichtbar und nutzbar. Pro Antwort und Stufe: Bewertung richtig / teilweise richtig / falsch, Kommentar und optional ergänzendes Wissen. Ergänzungen werden als Dokument `KOR-nnn` (Kategorie «Ergänzung (Testing)») eingebettet und sind sofort durchsuchbar; in der Wissensbasis wie andere Dokumente inaktivierbar. Zähler der Bewertungen im Schalterbalken. |
| Testauswertung | `/api/admin/ratings?format=csv` (mit `ADMIN_TOKEN`) liefert alle Bewertungen als CSV für Excel – Grundlage für die KPI-Messung (Korrektheit, Kalibrierung der Ampel) |
| Diagnose | `/api/admin/ask?q=…&level=…` zeigt Suchtreffer, Scores und Zeiten; `/api/admin/search?q=…` nur die Suche; Logs im Vercel-Dashboard |
| Nutzung auswerten | Vercel-Dashboard → Analytics (Seitenaufrufe, Besuche, Geräte) – Beleg für KPI «Nutzungsrate» |
| Kosten prüfen | Google AI Studio → Nutzung; Vercel und Neon im Dashboard |

## 8. Erste Testergebnisse (02.11.2026)

| Frage | Stufe | Ergebnis | Zeit |
|---|---|---|---|
| Was passiert bei einem Timeout im Instant Payment? | Basic | 🟢 85 %, korrekt, Quellen PAY-02, IF-01, SH-01 | 2,4 s |
| Darf der KI-Assistent im Fraud-Jour-fixe mitlaufen? | Instant | 🟡 84 %, inhaltlich richtig («Nein»), Quelle nur WE-03 | 2,1 s |
| Wie hoch sind die Hypothekarzinsen? (nicht in der Wissensbasis) | Instant | 🔴 0 %, ehrlich «nicht im Kontext», 3 Vorschläge, Ansprechstelle | 1,5 s |
| Wo steht in der camt.054 die QR-Referenz? (nur Suche) | – | Top 3 Treffer alle aus IF-02 | 0,4 s |

## 9. Bekannte Schwächen und nächste Schritte

| Befund | Massnahme | Wer / bis |
|---|---|---|
| Entscheid E2 aus MP-05 wird bei der Fraud-Frage nicht gefunden | Testfall aufnehmen; Suche und Abschnittsgrösse für Protokolle prüfen | JJ, Deniz / M3 22.11. |
| Bei Gelb fehlen teilweise die Vorschläge | Prompt-Regel schärfen | Deniz / M3 |
| Basic-Antwort vermischte zwei Timeout-Arten | Testfall aufnehmen, Prompt-Regel «Begriffe nicht vermischen» | JJ, Deniz / M3 |
| Fehlermeldungen (Upload, Ersetzen, Antwort) | Umgesetzt 02.11.: verständliche Meldungen mit nächstem Schritt, z. B. Dateityp, Grösse, gescanntes PDF, ausgelasteter KI-Dienst, abgelaufene Anmeldung; technische Details nur im Log | – |
| XML-Beispiel in IF-02 wird in der Aufbereitung zerlegt | Code-Blöcke in `build_chunks.py` erhalten | Deniz / M3 |
| Ampel-Schwellen sind Startwerte | Kalibrierung mit Testset (30 Fragen) | Peri, JJ / M4 29.11. |

| Befund | Massnahme | Wer / bis |
|---|---|---|
| 15 Dokumente ohne Owner im Kopf (Leitfäden, Transkripte, 2 Produktblätter) | Owner ergänzen vor Freeze | JJ / M2 14.11. |