Modellwahl (Schritt 2)

Stand: 02.11.2026 · **Verantwortlich:** Deniz (Tech Lead) · **Anbieter:** Google Gemini API, bezahlte Stufe (Prepaid-Guthaben CHF 16, seit 02.11.2026)

Entscheid

Aufgabe	Modell	Begründung
Embedding (Suche)	`gemini-embedding-2`	Allgemein verfügbar (nicht Preview), mehrsprachig, bis 8'192 Tokens pro Abschnitt; Vektoren mit 768 Dimensionen (kompakt, gut für pgvector)
Antwort Instant und Basic	`gemini-3.5-flash-lite`	Antwortzeit im Test 0,7 s – erfüllt das Ziel «Instant < 5 s» im Meeting
Antwort Full	`gemini-3.5-flash` (Thinking minimal)	Etwas stärker für längere Zusammenfassungen, im Test 1,2 s
Ausweichmodell	`gemini-flash-lite-latest`	Falls ein Modell überlastet ist (Fehler 503)

Alle Modellnamen sind als Umgebungsvariablen konfigurierbar; ein Wechsel braucht keine Codeänderung.

Testlauf vom 02.11.2026

Getestet über `/api/admin/probe` mit dem Projektschlüssel (damals noch Gratis-Stufe), Frage: «Was ist ein Instant Payment?»

Modell	Ergebnis	Antwortzeit
gemini-embedding-2	OK, 768 Dimensionen	0,3 s
gemini-embedding-001	OK, 768 Dimensionen	0,3 s
gemini-3.8-flash (Standard)	OK, korrekt	**85 s** – für Live-Einsatz untauglich
gemini-3.5-flash (Thinking minimal)	OK, korrekt	1,2 s
gemini-3.5-flash-lite	OK, korrekt	0,7 s
gemini-flash-lite-latest	OK, korrekt	0,8 s
gemini-3.1-flash-lite	Fehler 503 (Überlast)	–
gemini-2.5-flash	Fehler 404 (für neue Nutzer nicht mehr verfügbar)	–

Erkenntnisse für Präsentation und Diskussion

- **Neuestes Modell ≠ bestes Modell für den Zweck:** Das neueste Flash-Modell lieferte gute Qualität, aber 85 s Wartezeit. Für Instant im Meeting zählt Geschwindigkeit.

- **Modelle verschwinden:** Ein ein Jahr altes Modell (2.5 Flash) ist bereits abgekündigt. Deshalb konfigurierbare Modellnamen und ein Ausweichmodell.
- **Von Gratis- auf bezahlte Stufe (02.11.2026):** Beim ersten Import stiess die Gratis-Stufe an ihre Grenze (100 Embeddings pro Minute). Mit einem Prepaid-Guthaben von CHF 16 entfallen diese Limiten. Zudem nutzt Google Eingaben in der bezahlten Stufe nicht zur Verbesserung seiner Modelle – in der Gratis-Stufe wäre das erlaubt gewesen (für fiktive Daten vertretbar, für echte Daten nicht).
- **Effektive Kosten PoC:** Guthaben CHF 16 (Verbrauch laufend in Google AI Studio einsehbar); Vercel, Neon und GitHub im Gratis-Kontingent.