Testkonzept und Testautomatisierung

Stand: 02.11.2026 · **Verantwortlich:** Deniz (technisch), JJ (fachlich), Peri (Auswertung)

1. Übersicht

Ebene	Was wird geprüft	Wie	Wann
1. Unit-Tests	Rechenlogik ohne Netz: Ampel, Kalibrierung, Weiterweg bei Gelb/Rot, Längenvorgabe, Aufteilen in Abschnitte, Dateiprüfung, Sitzung, Passwort-Hashes, Rollenmodell, Quellen-Links	Vitest, `app/tests/unit/`	bei jedem Push (GitHub Actions)
2. API-Tests	Zugangsschutz (Proxy), Login, Rechte je Rolle für alle schreibenden Funktionen, Eingabeprüfung der Benutzerverwaltung; Datenbank und KI werden simuliert	Vitest, `app/tests/api/`	bei jedem Push
3. Build	App lässt sich fehlerfrei bauen	`next build`	bei jedem Push
4. Live-Smoke	Produktion erreichbar, ohne Anmeldung gesperrt, Admin-API nur mit Token, falsches Passwort abgewiesen, Datenbank gefüllt	`app/tests/live/run.mjs`	nach jedem Push (nach dem Deployment) und werktags um 06:17 Uhr
5. Live-Regression	Referenzfragen gegen die echte App: richtige Quelle, erlaubte Ampelfarbe, Pflichtbegriffe, Länge je Stufe, nie eine Sackgasse	`tests/regression.json` + `run.mjs`	wie Smoke
6. Fachliches Testing	Korrektheit, Vollständigkeit, Halluzinationen und Kalibrierung der Ampel anhand des Testkatalogs	JJ im Testing-Modus der App, Export als CSV	bis M4 (29.11.)

Die Ebenen 1 bis 5 laufen automatisch, Ebene 6 ist manuell und fachlich. Befunde aus Ebene 6 werden als Referenzfragen in Ebene 5 übernommen. So bleibt ein einmal behobener Fehler behoben.

2. Ausführen

```
cd app
npm test                        # Ebenen 1–2 (ca. 3 s, ohne Internet und Zugangsdaten)
npm run test:watch              # während der Entwicklung
BASE_URL=https://zhaw-lnw-mod2.vercel.app ADMIN_TOKEN=… npm run test:live   # Ebenen 4–5
ONLY=R01,R11 … npm run test:live                                           # nur einzelne Fragen
```

GitHub Actions (`.github/workflows/tests.yml`) läuft automatisch bei jedem Push und Pull Request, werktags am Morgen und auf Knopfdruck über Actions → Tests → Run workflow. Für die Live-Tests braucht das Repository das Secret `ADMIN_TOKEN`. Fehlt es, werden die Live-Tests mit einer Warnung übersprungen. Den Bericht gibt es als Download `live-bericht` beim jeweiligen Lauf.

3. Referenzfragen erweitern (für JJ)

Datei `tests/regression.json`, ein Eintrag pro Frage:

```
{ "id": "R13", "kategorie": "Prozess", "frage": "…", "level": "basic",
  "expect_docs": ["PAY-02"], "lights": ["green", "yellow"], "must_contain": ["SIC5"] }
```

- `expect_docs`: mindestens eine dieser Quellen muss genannt sein; leer bei Fragen ausserhalb der Wissensbasis
- `lights`: erlaubte Ampelfarben
- `must_contain`: Begriffe, die in der Antwort stehen müssen, zum Beispiel Fristen oder Beträge
- `bekannt`: dokumentierter, noch offener Befund. Er wird gemeldet, lässt den Lauf aber nicht scheitern.

Faustregel: Eine Frage wird hier aufgenommen, wenn sie für die Präsentation wichtig ist oder schon einmal falsch beantwortet wurde.

4. Ergebnisse 02.11.2026

Unit- und API-Tests: 84 von 84 bestanden. Build erfolgreich, auch in GitHub Actions.

Live-Regression (12 Referenzfragen), erster Lauf:

ID	Frage (gekürzt)	Ergebnis	Befund
R01	Ablauf Instant Payment (Basic)	🟢 100, PAY-02/PB-02	✘ Antwort nur 1 Satz (15 Wörter) statt 150–250 → **behoben**
R02	Timeout PayHub ↔ ScreenGuard	🟢 100, IF-01	✔ 800 ms Instant, 5 s Standard
R03	Inhalt camt.054	🟢 95, IF-02, PAY-03, AA-05, PB-01	✔
R04	Authentifizierung Payment Initiation API	🔴 40, IF-03	⚠ OAuth2/mTLS steht in IF-03, wird aber als «nicht beschrieben» gewertet → **bekannter Befund**, Backlog
R05	Ablösung LSV+	🟢 100, PAY-07, MP-02	✔ 30.09.2028
R06	Sanktionsalarm Level 1	🟡 84, AA-03, SH-02, PAY-08	✔ Gelb wegen mittlerer Suchtreffer, Ansprechstelle genannt
R07	Sofortmassnahmen Betrugsverdacht	🟢 100, LF-02, AA-04, PAY-10	✔
R08	Preis SEPA-Überweisung Privatkunden	🟢 100, PB-01	✔ CHF 2.00
R09	Verdachtsmeldung MROS	🟢 100, WE-01, COM-02	✔
R10	Zuständigkeit PayHub	🟢 95, SH-01, ORG-01	✔
R11	Hypothekarzins (nicht in Wissensbasis)	🔴 0	✘ ehrlich «nicht im Kontext», aber **ohne Vorschläge und Ansprechstelle** (Sackgasse) → **behoben**

ID	Frage (gekürzt)	Ergebnis	Befund
R12	Fussball-WM (themenfremd)	🔴 0	✔ 3 Vorschläge, Ansprechstelle

Korrekturen aus dem Lauf (live seit 02.11., 14:04 Uhr, Commit `16e0f1b`):

- **Nie eine Sackgasse:** Gibt das Modell bei Gelb oder Rot keinen Weiterweg an, ergänzt die App feste Vorschläge und die Ansprechstelle gemäss Organigramm (ORG-01). Nachtest R11: 3 Vorschläge und eine Ansprechstelle.
- **Längenvorgabe:** Ist eine Basic- oder Full-Antwort trotz guter Datenlage zu kurz (Basic unter 80, Full unter 300 Wörtern), wird sie einmal neu erzeugt. Das kostet etwa 2 Sekunden und betrifft nur diese Fälle. Nachtest R01: 136 Wörter, 5 Stichpunkte.

Ergebnis nach Korrektur: 11 von 12 bestanden, 1 bekannter Befund (R04).

5. Grenzen

- Die Live-Tests prüfen Form und Quellen, aber nicht die fachliche Richtigkeit jedes Satzes. Das leistet das fachliche Testing (Ebene 6).
- Antworten eines Sprachmodells schwanken leicht. Die Regression lässt deshalb Bandbreiten zu, zum Beispiel Grün oder Gelb, und mehrere mögliche Quellen.
- Jeder Live-Lauf kostet einige Rappen Gemini-Guthaben (12 Fragen, rund 25 Modellaufrufe).